

MATHBACAI.COM — TOME 2 — CHAPITRE 10

60 QUESTIONS & RÉPONSES CLÉS : STATISTIQUES

Q1. Qu'est-ce qu'une série statistique double ?

C'est l'observation simultanée de deux caractères quantitatifs notés X et Y sur une même population de n individus. On obtient ainsi un ensemble de couples (x_i, y_i) de coordonnées.

Q2. Comment est défini le point moyen G d'une série statistique double ?

Le point moyen G est le point théorique du plan dont les coordonnées sont la moyenne arithmétique de chaque variable, noté $G(\bar{X}, \bar{Y})$.

Q3. Quelle est la formule mathématique pour calculer $\bar{X}$?

$\bar{X} = (1/n) \cdot \sum (x_i)$ pour i variant de 1 à n .

Q4. Quelle est la formule mathématique pour calculer $\bar{Y}$?

$\bar{Y} = (1/n) \cdot \sum (y_i)$ pour i variant de 1 à n .

Q5. Le point moyen G appartient-il toujours au nuage de points ?

Non, pas nécessairement. C'est un point fictif/théorique représentant le barycentre du nuage de points.

Q6. Qu'est-ce qu'un nuage de points dans un repère du plan ?

C'est la représentation graphique de la série double où chaque couple de données (x_i, y_i) est représenté par un point $M_i(x_i, y_i)$.

Q7. Quelle est l'utilité première du nuage de points ?

Il permet de visualiser la forme de la distribution globale et de conjecturer l'existence d'une relation (linéaire, exponentielle, etc.) entre les deux caractères X et Y .

Q8. Qu'est-ce qu'un ajustement affine ?

C'est la recherche d'une relation linéaire (droite) de la forme $y = ax + b$ qui décrit au mieux le lien entre Y et X afin d'estimer ou de prédire de futures valeurs.

Q9. Quand dit-on qu'un ajustement affine est légitime ?

Lorsque la forme générale du nuage de points est allongée (forme de fuseau) et que les points semblent s'aligner le long d'une direction rectiligne.

Q10. Quelle est la définition de la variance $V(X)$ de la variable X ?

C'est la moyenne des carrés des écarts à la moyenne : $V(X) = (1/n) \cdot \sum (x_i - \bar{X})^2$. Par la formule de König-Huygens, on a : $V(X) = (1/n) \cdot \sum (x_i^2) - (\bar{X})^2$.

Q11. Quelle est la définition générale de la covariance de X et Y ?

La covariance mesure la variation conjointe des deux caractères. Elle est donnée par : $\text{Cov}(X, Y) = (1/n) \cdot \sum (x_i - \bar{X})(y_i - \bar{Y})$.

Q12. Énoncez la formule de König-Huygens pour le calcul de la covariance.

$\text{Cov}(X,Y) = (1/n) \cdot \text{Sum} (x_i \cdot y_i) - (X_{\text{bar}} \cdot Y_{\text{bar}})$. C'est la formule la plus pratique pour les calculs analytiques.

Q13. Quel est le signe de la covariance si X et Y varient dans le même sens ?

La covariance est strictement positive ($\text{Cov}(X,Y) > 0$).

Q14. Quel est le signe de la covariance si Y diminue lorsque X augmente ?

La covariance est strictement négative ($\text{Cov}(X,Y) < 0$).

Q15. La covariance dépend-elle de l'unité des variables ?

Oui, contrairement au coefficient de corrélation, la covariance varie selon les unités de mesure utilisées pour X et Y.

Q16. Que peut-on dire si la covariance est nulle ?

S'il n'y a aucune relation linéaire entre X et Y, la covariance est nulle (ou proche de 0). Cependant, cela n'exclut pas une relation non linéaire (quadratique, etc.).

Q17. Quelle est la covariance d'une variable X avec elle-même, soit $\text{Cov}(X,X)$?

La covariance d'une variable avec elle-même est égale à sa propre variance : $\text{Cov}(X,X) = V(X)$.

Q18. Quelle est la définition du coefficient de corrélation linéaire r ?

C'est le rapport de la covariance de X et Y sur le produit de leurs écarts-types respectifs : $r = \text{Cov}(X,Y) / (\sigma_X \cdot \sigma_Y)$.

Q19. Dans quel intervalle de valeurs se situe obligatoirement le coefficient r ?

Il appartient strictement à l'intervalle $[-1, 1]$.

Q20. Que signifie un coefficient de corrélation r proche de 1 ?

Il indique une corrélation linéaire positive très forte : les points sont presque parfaitement alignés sur une droite de pente positive.

Q21. Que signifie un coefficient de corrélation r proche de -1 ?

Il indique une corrélation linéaire négative très forte : les points sont presque parfaitement alignés sur une droite de pente négative.

Q22. Que signifie un coefficient de corrélation r proche de 0 ?

Il indique l'absence totale de corrélation linéaire entre les variables X et Y.

Q23. À partir de quelle valeur de $|r|$ considère-t-on que l'ajustement linéaire est de très bonne qualité ?

Dans la pratique du Baccalauréat Tunisien, on considère l'ajustement de très bonne qualité lorsque $|r| \geq 0.95$ (ou $r^2 \geq 0.90$).

Q24. Le coefficient de corrélation linéaire r est-il influencé par un changement d'unité ?

Non, le coefficient de corrélation r est un nombre adimensionnel (sans unité). Il est insensible aux changements d'unités de mesure.

Q25. Si $y = -3x + 2$ est la relation exacte entre X et Y, quelle est la valeur de r ?

Puisque la relation linéaire est parfaite et décroissante (pente -3 négative), le coefficient r vaut exactement -1.

Q26. Qu'est-ce que la méthode des moindres carrés ?

C'est une méthode d'ajustement consistant à trouver la droite $y = ax + b$ qui minimise la somme des carrés des écarts verticaux entre les points réels et la droite.

Q27. Quelle est l'équation de la droite de régression de Y en X ?

L'équation réduite est : $y = a \cdot x + b$.

Q28. Donnez la formule du coefficient directeur 'a' de la droite de régression de Y en X.

$$a = \text{Cov}(X,Y) / V(X).$$

Q29. Donnez la formule de l'ordonnée à l'origine 'b' de la droite de régression de Y en X.

$$b = Y_{\text{bar}} - a \cdot X_{\text{bar}}.$$

Q30. Donnez la propriété fondamentale de passage de la droite de régression de Y en X.

La droite de régression passe obligatoirement par le point moyen $G(X_{\text{bar}}, Y_{\text{bar}})$.

Q31. Quelle est l'équation de la droite de régression de X en Y ?

L'équation est de la forme : $x = a' \cdot y + b'$.

Q32. Donnez la formule du coefficient directeur 'a' de la droite de régression de X en Y.

$$a' = \text{Cov}(X,Y) / V(Y).$$

Q33. Donnez la formule de 'b' pour la droite de régression de X en Y.

$$b' = X_{\text{bar}} - a' \cdot Y_{\text{bar}}.$$

Q34. Les droites de régression de Y en X et de X en Y sont-elles confondues ?

Elles ne sont confondues que dans le cas d'une corrélation parfaite ($|r| = 1$). Sinon, elles sont distinctes mais se coupent toutes les deux au point moyen G.

Q35. Quel est le produit des coefficients directeurs a et a' ?

Le produit $a \cdot a'$ est égal au carré du coefficient de corrélation : $a \cdot a' = (\text{Cov}(X,Y)/V(X)) \cdot (\text{Cov}(X,Y)/V(Y)) = r^2$.

Q36. Comment calculer l'écart-type σ_X à partir de la variance $V(X)$?

$$\sigma_X = \text{racine}(V(X)).$$

Q37. Qu'est-ce qu'une estimation par extrapolation ?

C'est l'utilisation de l'équation de la droite de régression pour estimer une valeur de Y en dehors de l'intervalle d'observation des valeurs de X.

Q38. Qu'est-ce qu'une estimation par interpolation ?

C'est l'estimation d'une valeur de Y pour une valeur de X intermédiaire située à l'intérieur de la plage des données observées.

Q39. Comment justifier la pertinence d'une prédiction à l'aide de r ?

On calcule r. Si $|r| \geq 0.95$, la prédiction est hautement fiable car le modèle affine décrit très bien la réalité.

Q40. Comment modéliser une relation non linéaire, par exemple si $y = k \cdot e^{(m \cdot x)}$?

On effectue un changement de variable en posant $Z = \ln(Y)$. L'équation devient $\ln(Y) = \ln(k) + m \cdot x$, soit $Z = A \cdot x + B$, ce qui permet de faire un ajustement linéaire sur (X, Z).

Q41. Si $\text{Cov}(X,Y) = 12$, $V(X) = 16$ et $V(Y) = 25$, calculez r.

$\sigma_X = \sqrt{16} = 4$, $\sigma_Y = \sqrt{25} = 5$. $r = 12 / (4 \cdot 5) = 12 / 20 = 0.60$. La corrélation est positive mais modérée.

Q42. Avec les données précédentes, donnez la pente 'a' de la droite de régression de Y en X.

$a = \text{Cov}(X,Y) / V(X) = 12 / 16 = 0.75$.

Q43. Que vaut le coefficient r si la covariance de la série double est de -8.5, et que les écarts-types valent respectivement 3 et 4 ?

$r = -8.5 / (3 \cdot 4) = -8.5 / 12 \approx -0.71$.

Q44. Comment le point moyen G aide-t-il à tracer la droite de régression ?

Il sert de point de pivot : pour tracer la droite, il suffit de calculer un autre point (x, y) grâce à l'équation $y = ax+b$, puis de joindre ce point au point moyen G.

Q45. Qu'est-ce qu'une série statistique marginale pour X ?

C'est l'étude de la variable unique X indépendamment de la variable Y, représentée par la première ligne ou première colonne de totaux du tableau à double entrée.

Q46. Quel est le lien entre le coefficient de corrélation r et le coefficient de détermination R^2 ?

Le coefficient de détermination R^2 est simplement le carré du coefficient de corrélation r. Il exprime la proportion de la variance de Y expliquée par la droite de régression de X.

Q47. Expliquez le rôle des résidus dans la méthode des moindres carrés.

Un résidu est la différence verticale $e_i = y_i - (a \cdot x_i + b)$. Les moindres carrés minimisent la somme $\sum (e_i)^2$.

Q48. Si on effectue un changement de variable affine $X' = 2X + 1$, que devient la moyenne X'_{bar} ?

Par linéarité de la moyenne, $X'_{\text{bar}} = 2 \cdot X_{\text{bar}} + 1$.

Q49. Si on pose $Y' = -3Y$, que devient l'écart-type $\sigma_{Y'}$?

L'écart-type est toujours positif et multiplié par la valeur absolue du coefficient : $\sigma_{Y'} = |-3| \cdot \sigma_Y = 3 \cdot \sigma_Y$.

Q50. Si $Y' = 2Y + 5$ et $X' = X - 2$, comment varie la covariance $\text{Cov}(X', Y')$ par rapport à $\text{Cov}(X, Y)$?

$\text{Cov}(aX+b, cY+d) = a \cdot c \cdot \text{Cov}(X, Y)$. Ici, $\text{Cov}(X', Y') = 1 \cdot 2 \cdot \text{Cov}(X, Y) = 2 \cdot \text{Cov}(X, Y)$.

Q51. Comment le coefficient r change-t-il si X et Y sont permutés ?

Le coefficient de corrélation r est symétrique : $r(X, Y) = r(Y, X)$. Il ne change donc pas.

Q52. Les droites de régression se coupent-elles toujours en G ?

Oui, les deux droites de régression de Y en X et de X en Y passent par le point moyen G , elles s'y croisent donc systématiquement.

Q53. Quelle est la pente de la droite de régression de X en Y exprimée sous la forme $y = \dots$?

La droite est $x = a'y + b'$, soit $y = (1/a')x - b'/a'$ (si a' non nul).

Q54. Si le coefficient de corrélation r vaut 0.99, l'ajustement affine est-il fiable ?

Oui, extrêmement fiable puisque $0.99 > 0.95$, indiquant un fort alignement rectiligne.

Q55. Est-il possible d'avoir $r = 1.25$?

Non, c'est impossible car le coefficient r est mathématiquement borné entre -1 et 1.

Q56. La somme des résidus e_i d'une droite de régression est-elle nulle ?

Oui, pour la droite des moindres carrés, la somme algébrique des résidus $\sum (y_i - a \cdot x_i - b)$ est toujours exactement égale à 0.

Q57. Pourquoi privilégie-t-on le carré des résidus au lieu des valeurs simples ?

Pour éviter que les résidus positifs et négatifs ne se compensent, et pour pénaliser plus lourdement les grands écarts.

Q58. Qu'est-ce qu'une droite de Mayer ?

C'est une autre méthode d'ajustement consistant à séparer le nuage de points en deux sous-groupes d'effectifs égaux, de calculer le point moyen de chaque groupe, et de tracer la droite passant par ces deux points.

Q59. L'ajustement par la droite de Mayer est-il aussi précis que les moindres carrés ?

Non, la méthode des moindres carrés est théoriquement plus robuste car elle minimise mathématiquement l'erreur quadratique totale.

Q60. Donnez un exemple d'application des séries doubles pour l'ingénieur.

Estimer la résistance d'un matériau Y en fonction de la température de cuisson X , ou prédire l'usure d'un pneu en fonction du kilométrage parcouru.