

## TOME 2 — CHAPITRE 10

# LES STATISTIQUES À DEUX VARIABLES

Séries Doubles, Covariance, Coefficient de Corrélation de Pearson, Droite de Régression  
Linéaire par les Moindres Carrés.

**Section :** Baccalauréat Tunisien (4ème Sciences Mathématiques)  
**Rédigé de manière rigoureuse et structurée**  
**Conforme aux exigences du Ministère de l'Éducation Tunisien**

# Partie 1 : Séries Statistiques Doubles & Nuage de Points

Ce chapitre traite de l'analyse conjointe de deux variables observées simultanément.

## 1. Définition d'une Série Statistique Double

Une série statistique double correspond à l'observation simultanée de deux caractères quantitatifs  $X$  et  $Y$  sur une population de  $n$  individus. On obtient une série de  $n$  couples d'observations notée :

$$(x_i, y_i) \text{ pour } i \text{ allant de } 1 \text{ à } n$$

Où  $x_i$  désigne la valeur du caractère  $X$  de l'individu  $i$ , et  $y_i$  désigne la valeur de son caractère  $Y$ .

### Point Moyen d'un Nuage de Points (G)

On appelle **Point Moyen G** du nuage de points l'unique point théorique représentant le centre de gravité des observations, défini par ses coordonnées moyennes :

$$\bar{X} = (1/n) \cdot (x_1 + x_2 + \dots + x_n)$$


$$\bar{Y} = (1/n) \cdot (y_1 + y_2 + \dots + y_n)$$

Le point moyen **G**( $\bar{X}$ ,  $\bar{Y}$ ) est un repère géométrique fondamental par lequel passera l'unique droite de régression linéaire de la série.

## 2. Nuage de Points Associé

Dans un repère du plan, chaque couple  $(x_i, y_i)$  est représenté par un point géométrique  $M_i(x_i, y_i)$ . L'ensemble de ces points constitue le **nuage de points** de la série double.

L'observation visuelle de ce nuage permet d'évaluer immédiatement la pertinence d'une relation (linéaire, exponentielle, etc.) entre les deux caractères.



**Fig 1** : Représentation du nuage de points d'une série double avec son Point Moyen G( $\bar{X}$ ,  $\bar{Y}$ ).

# Partie 2 : Covariance d'une Série Statistique Double

La covariance mesure la variation conjointe des deux caractères de la série double.

## 1. Définition de la Covariance

La covariance de X et Y, notée  $\text{Cov}(X, Y)$ , est la moyenne arithmétique des produits des écarts de X et Y par rapport à leurs moyennes respectives :

$$\text{Cov}(X, Y) = (1/n) \cdot \sum (x_i - \bar{X})(y_i - \bar{Y})$$

### Formule de König-Huygens (Calcul Rapide)

Pour calculer rapidement et sans perte de précision la covariance d'une série au Baccalauréat, on utilise la formule de König-Huygens :

$$\text{Cov}(X, Y) = [ (1/n) \cdot (x_1 \cdot y_1 + x_2 \cdot y_2 + \dots + x_n \cdot y_n) ] - (\bar{X} \cdot \bar{Y})$$

Autrement dit, la covariance est égale à la *moyenne des produits moins le produit des moyennes*.

## 2. Interprétation du Signe de la Covariance

Le signe de  $\text{Cov}(X, Y)$  est extrêmement structurant pour comprendre l'évolution conjointe :

- **Si  $\text{Cov}(X, Y) > 0$**  : Les caractères X et Y évoluent globalement dans le même sens (lorsque X augmente, Y a tendance à augmenter également). Le nuage présente une inclinaison positive (pente ascendante).
- **Si  $\text{Cov}(X, Y) < 0$**  : Les caractères X et Y évoluent en sens inverse (lorsque X augmente, Y a tendance à diminuer). Le nuage présente une inclinaison négative (pente descendante).
- **Si  $\text{Cov}(X, Y) = 0$**  : Il n'y a pas d'évolution linéaire conjointe évidente.

# Partie 3 : Corrélation Linéaire & Force de Liaison

Le coefficient  $r$  mesure la qualité et la force d'un ajustement rectiligne.

## 1. Le Coefficient de Corrélation Linéaire $r$

Pour quantifier rigoureusement l'intensité de la relation linéaire, on définit le coefficient de corrélation de Pearson, noté  $r$  :

$$r = \text{Cov}(X, Y) / (\sigma_X \cdot \sigma_Y)$$

Où  $\sigma_X$  désigne l'écart-type de la variable  $X$  (racine carrée de la variance  $V(X)$ ), et  $\sigma_Y$  désigne l'écart-type de la variable  $Y$ .

### Règle de Décision du Baccalauréat pour l'Ajustement

1. Le coefficient de corrélation  $r$  est toujours compris entre **-1 et 1** :  $-1 \leq r \leq 1$ .
2. Si  $|r| \geq 0.95$  (ou si  $r^2 \geq 0.90$ ), on considère que le nuage de points est fortement étiré le long d'une droite.  
**L'ajustement affine est alors de très bonne qualité** et permet d'utiliser le modèle d'équation pour effectuer des prévisions fiables.

## 2. Comparaison Visuelle des Liaisons

Ci-dessous la différence entre une corrélation forte (ajustement linéaire parfait) et une corrélation faible (points dispersés) :




Fig 3 : Différence de répartition géométrique d'un nuage de points en fonction de la valeur de son coefficient  $|r|$ .

# Partie 4 : Droite de Régression par les Moindres Carrés

La droite optimale minimisant les erreurs de prévision pour les élèves de Terminale.

## 1. Droite de Régression de Y en X

La droite de régression de Y en X, notée  $D_{(Y/X)}$ , est l'unique droite d'ajustement affine :

$$y = a \cdot x + b$$

qui minimise la somme des carrés des écarts verticaux entre les points réels du nuage et la droite.

### Formules de Détermination des Coefficients a et b

- Le coefficient directeur (pente) **a** de la droite de Y en X vaut :

$$a = \text{Cov}(X, Y) / V(X)$$

- L'ordonnée à l'origine **b** vaut :

$$b = Y_{\text{bar}} - a \cdot X_{\text{bar}}$$

La droite de régression de Y en X passe obligatoirement par le Point Moyen de la série  $G(X_{\text{bar}}, Y_{\text{bar}})$ .

## 2. Écarts Résiduels et Moindres Carrés

Le principe des moindres carrés cherche à rendre la somme des carrés des erreurs de prévision (résidus  $e_i = y_i - (a \cdot x_i + b)$ ) la plus petite possible. Ceci évite les compensations de signes entre résidus positifs et négatifs.




Fig 2 : Droite d'ajustement affine passant de manière optimale à travers le nuage et le point G.




Fig 4 : Visualisation géométrique des écarts résiduels verticaux minimisés par le modèle.